# 索引的创建

# 现代计算机的体系结构

 $CPU \rightarrow Cache \rightarrow RAM \rightarrow Hard\ Disk \rightarrow Off Line\ Storage$ 

小、快、贵 → 大、慢、廉

Data Access Locality (More High More Efficient)

# Problem 1

内存无法容纳所有的索引项

### Solution

BSBI: Bolcked sorted-based indexing

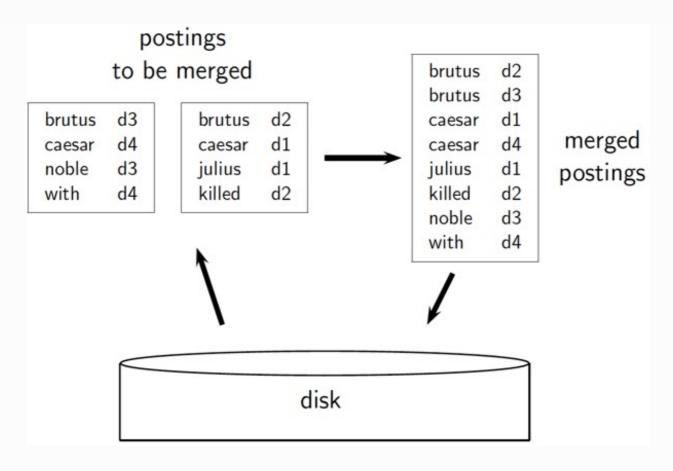
#### **BSBI**

#### 思想:

- 同时使用内存和磁盘。
- 把尽量多的工作放到内存内完成。
- 对磁盘的访问尽量使用顺序读写。

#### 方法:

- 将文档集分块,使得每块都能被内存容纳。
- 在内存中对每块的内容进行排序,并写回磁盘。
- 将各块的排序进行合并,并创建posting lists.



BSBI算法复杂度: 4SN 约为将文档读入内存四次的代价

#### BSBIndexConstruction()

- $1 \quad n \leftarrow 0$
- 2 while (all documents have not been processed)
- 3 **do**  $n \leftarrow n + 1$
- 4  $block \leftarrow ParseNextBlock()$
- 5 BSBI-Invert(block)
- 6 WRITEBLOCKTODISK(block,  $f_n$ )
- 7 Mergeblocks( $f_1, \ldots, f_n; f_{\text{merged}}$ )

**Figure 4.2** Blocked sort-based indexing. The algorithm stores inverted blocks in files  $f_1, \ldots, f_n$  and the merged index in  $f_{\text{merged}}$ .

## Problem 2

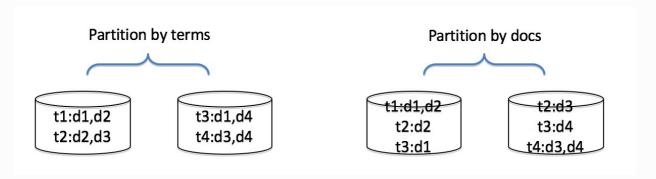
单个计算机无法容纳所有的索引项

### Solution

分布式系统 - Cluster

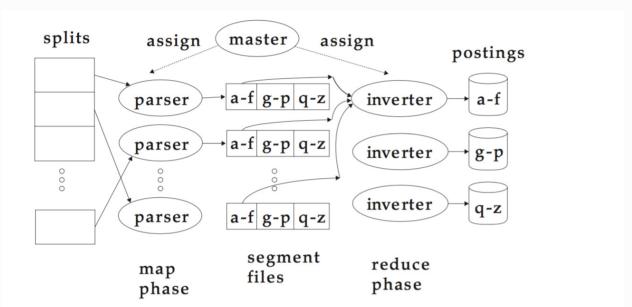
## 分布式的倒排索引

- Partition By Terms (有些节点会被密集访问,有的节点就浪费了/负载不平衡)
- Partition By Docs (Google Choose This Way)



## MapReduce

- 1. Map (将一个大任务分解为多个小任务,解决每个小任务)
- 2. Reduce (将小任务大答案进行合并,以得到大任务的答案)



**Figure 4.5** An example of distributed indexing with MapReduce. Adapted from Dean and Ghemawat (2004).

# Problem 3

文档在不断增加,索引项在不断增加

#### Solution

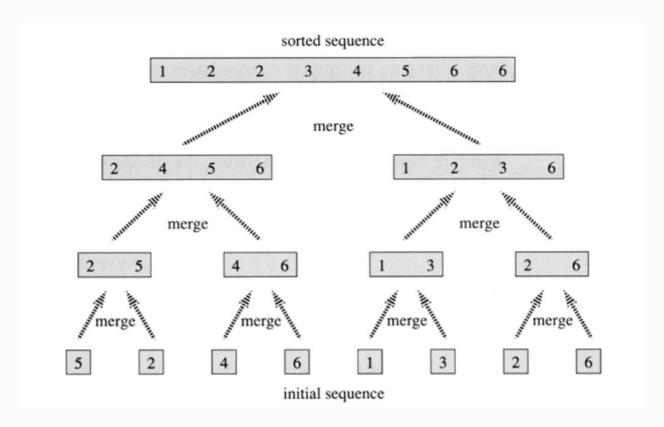
#### 动态索引

- 两个倒排索引:
  - 位于磁盘上的静态索引
  - 位于内存中的动态辅助索引

- 查询时合并两个索引结果
- 新来的文档加入辅助索引
- 当辅助索引过满时、合并到磁盘上的主索引、再清空
- 复杂度: O(n²)

# Logarithmic Merge

- 多个索引
  - 最底层主索引
  - 上层索引大小为下层的1/2
  - 最高层位于内存中,其余位于磁盘上
- 查询时合并多个索引的结果
- 当上层索引填满时,与下一层索引合并
- 复杂度: O(nlogn)



```
LMERGEADDTOKEN (indexes, Z_0, token)
      Z_0 \leftarrow \text{MERGE}(Z_0, \{token\})
      if |Z_0| = n
  2
  3
         then for i \leftarrow 0 to \infty
                do if I_i \in indexes
  4
  5
                        then Z_{i+1} \leftarrow \text{MERGE}(I_i, Z_i)
                                (Z_{i+1} \text{ is a temporary index on disk.})
  6
  7
                               indexes \leftarrow indexes - \{I_i\}
                        else I_i \leftarrow Z_i (Z_i becomes the permanent index I_i.)
  8
                               indexes \leftarrow indexes \cup \{I_i\}
  9
 10
                               BREAK
                Z_0 \leftarrow \emptyset
 11
LogarithmicMerge()
     Z_0 \leftarrow \emptyset (Z_0 is the in-memory index.)
     indexes \leftarrow \emptyset
 2
 3 while true
 4 do LMERGEADDTOKEN(indexes, Z_0, GETNEXTTOKEN())
```