

# 线性判别函数


线性判别函数(两类)

$$g(x) = w^T x + b = \begin{cases} > 0 & w_1 \\ < 0 & w_2 \end{cases}$$

其中,  $g(x) = 0$  就是分类面方程

直观展示

解释



可以看出我们需要做的就是选择 $w$ , 而选择 $w$ 本质上就是寻找一个最佳的投影方向. 如左图, 数据投影到法向量之后就是一维数据的分类问题

## Fisher 线性判别

### Fisher判别的基本思想

- 直观描述
  - 投影后的数据满足
    - 两类之间的距离尽可能远
    - 每类自身尽可能紧凑
- 数学描述
  - 考虑投影后数据的均值和方差
    - 两类数据的均值
    - 两类数据的协方差

### 理论推导

以两类为例子

记原始数据的均值为 $m_1, m_2$ , 协方差为 $\Sigma_1, \Sigma_2$

记原始数据投影后数据的均值为 $\mu_1, \mu_2$ ，协方差为 $\sigma_1, \sigma_2$

其中易得

$$\mu_i = w^T m_i, \text{ 此处 } w \text{ 为 单位向量}$$
$$\sigma_i^2 = E(w^T x - E(w^T x))^2 = w^T E(x - E(x))^2 w = w^T \Sigma_i w$$

注:  $x^T y = (x, y)$ , 而内积可以看作一个向量在另一个向量上作投影, 直观地看  
 $(x, y) = \|x\| \|y\| \cos(\angle x, y)$

Fisher准则函数:

$$J_F(w) = \frac{(\mu_1 - \mu_2)^2}{\sigma_1^2 + \sigma_2^2}$$
$$w_{opt} = \arg \max J_F(w)$$

由准则函数进一步推导可得

$$J_F(w) = \frac{(\mu_1 - \mu_2)^2}{\sigma_1^2 + \sigma_2^2} = \frac{(w^T m_1 - w^T m_2)^2}{w^T \Sigma_1 w + w^T \Sigma_2 w} = \frac{w^T (m_1 - m_2)(m_1 - m_2)^T w}{w^T (\Sigma_1 + \Sigma_2) w}$$

据此可以定义

- 类间离散度矩阵

$$S_b = (m_1 - m_2)(m_1 - m_2)^T$$

- 类内总离散度矩阵

$$S_w = \Sigma_1 + \Sigma_2, S_w \text{ 正定}$$

- 若  $w^T S_w w = 0$  意味着所有的数据都被投影到了一点

$J_F(w)$  有上界, 所以最佳投影方向一定存在

$$J_F(w) = \frac{w^T S_b w}{w^T S_w w}$$
$$\Downarrow$$
$$J_F(w) \leq \frac{\lambda(S_b)_{max}}{\lambda(S_w)_{min}}$$

最优化问题构建

一定存在最优的  $w$  使得

$$w^T S_w w = 1$$

故我们的目标函数可以写为

$$\begin{aligned} \max w^T S_b w \\ \text{s.t. } w^T S_w w = 1 \end{aligned}$$

拉格朗日乘子法转变如下

$$L(w, \lambda) = w^T S_b w - \lambda(w^T S_w w - 1)$$

求导便得到

$$\frac{\partial L(w, \lambda)}{\partial w} = S_b w - \lambda S_w w = 0$$

此处因为  $S_w$  正定必可逆，如果我们等式两边同时乘  $S_w^{-1}$ ，可得

$$S_w^{-1} S_b w = \lambda w \quad \text{可见 } w \text{ 是矩阵 } S_w^{-1} S_b \text{ 的特征向量}$$

继续之前公式可得

$$(m_1 - m_2)(m_1 - m_2)^T w_{opt} = \lambda S_w w_{opt}$$

其中  $(m_1 - m_2)^T w_{opt}$  是一个数，同时参数  $\lambda$  也是一个数，我们求解  $w$  时只关注它的方向，所以可以把

两边的数字全部去掉，于是得到

$$\begin{aligned} (m_1 - m_2) &= S_w w_{opt} \\ \Downarrow \\ w_{opt} &= S_w^{-1} (m_1 - m_2) = (\Sigma_1 + \Sigma_2)^{-1} (m_1 - m_2) \end{aligned}$$

参数  $b$  的确定方式就很简单了

$$b = \frac{n_1 \mu_1 + n_2 \mu_2}{n_1 + n_2}, \text{ 其中 } n_1, n_2 \text{ 是两类样本的个数}$$

## 最小平方误差准则

线性回归模型的例子

$$f(x) = \beta_0 + \sum_{i=1}^n x_i \beta_i$$

将 1 放入  $X$  即增广矩阵，可写成

$$\hat{Y} = X\beta$$

基于Least square 得到

$$\min J(\beta) = \|Y - X\beta\|^2$$

求导可得

$$\frac{\partial J}{\partial \beta} = -2X^T(Y - X\beta_{opt}) = 0$$

于是有

$$Y = X\beta_{opt}$$

避免  $X$  不可逆，两边同乘  $X^T$

$$X^T Y = X^T X \beta_{opt}$$


所以可以得到

$$\beta_{opt} = (X^T X)^{-1} X^T Y = \frac{(X, Y)}{(X, X)}$$

---

## 最小错分样本数准则

有时，数据并不是线性可分的，比如



这样的情况下，我们最直接的想法就是考虑最小错分量

