文档搜索无法达到绝对准确！

- 语言本身的局限性
- 关键词表达能力有限（查询语句所表达的用户需求不清晰、歧义）
- 计算机的语义理解能力不够

如何衡量搜索的准确性

- 结果集中的相关文档越多越好（Precision）
- 尽量多的相关文档囊括到结果集中（Recall）

自由检索

布尔检索的局限

- 运算难以被大众接受
- 太死板

自由检索

- 查询语句为一组词汇
- 结果按照相关性顺序返回
- 匹配程度可一定程度放松

词的预处理

1. A document → A bag of terms
2. 减少文档中的噪音、排除歧义
    - 词干提取 （Stemming）

      Example：**automat**ion → **automat**e(s) \ **automat**ic \ **automat**ion

      效果：增加 Recall

      相关规则：sses→ss \ ies→i \ ational→ate \ tional→tion
    - 删除停止词 （Stop Words）

      定义：出现频繁，但是对语义没有帮助的词

      Example：a,an,the \ of,for,by \ it,they,them...

      效果：提高 Precision

      注意点：有些停止词有重要意义,不能直接去处 [let it be \ to be or not to be]
3. 不同语言需要些特殊处理
    - 中文需要分词
    - 德语有些词汇需要拆分
4. 标准化问题

Example: U.S.A , USA → USA / colour , color → color

补充内容

> From *Data Science For Business*

文本数据（Text data ）的特点

- Unstructured data （非结构化数据）
- Linguistic structure（语言结构）——NLP （自然语言处理）

文本数据的缺陷（Text data's problem —dirty data ）：

- 不按照语法规则书写，例如很多用户留言或评论（Ungrammatical)
- 拼写错误（misspell）
- 各种缩写简写（Abbreviate）
- 随意使用标点符号（Punctuate randomly）
- 各种同义词的使用（Synonyms ）
- 同形异词（Homograph）
- 同一词汇在不同领域的不同理解（Different domain）
- 很多词汇的理解需要基于上下文（Context）

Dirty data 需要经过预处理（preprocess）才能作为下一步模型的输入（input）

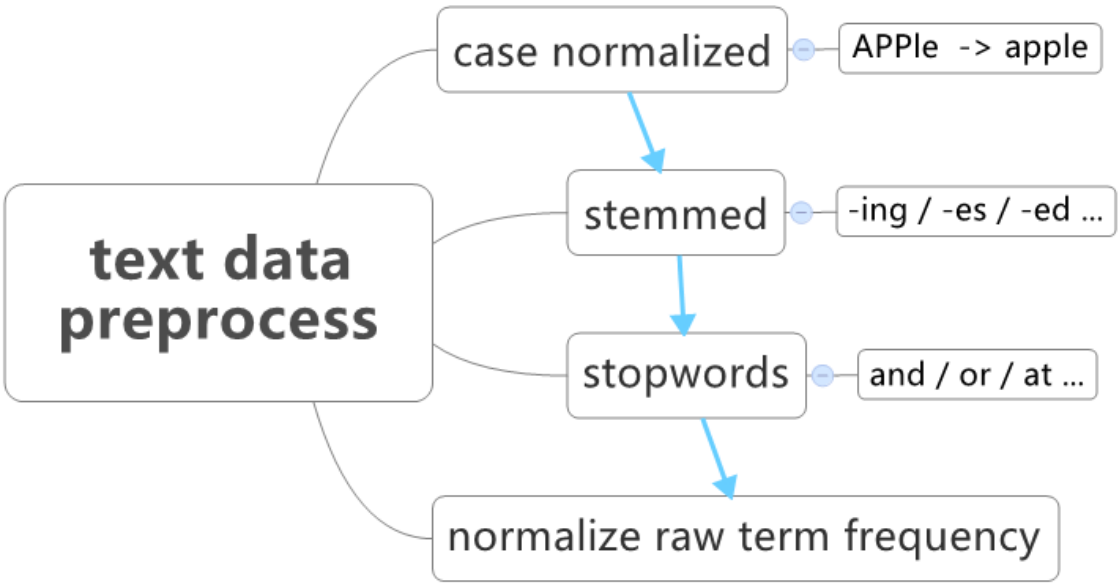

搜索结果排序

Process：

1. 得到所有可能相关的文档
2. 对文档**相关度**进行评估
3. 按相关度大小返回文档

模型

Bag of Words Model

查询语句（Q），文档集（D）$\rightarrow$ [0,1]

Term Frequency（TF)

一个词在一篇文档中出现的频率

$$TF(t,d)=\frac{文档\ d\ 中词汇\ t\ 的数量}{文档\ d\ 中词汇总量}$$

> Term frequency 有两点需要我们注意：
>
> - 太过稀有的词汇往往不加入考虑范畴。 对于聚类分析，低频的词汇往往没有太大作用，所以在预处理时，我们会设置一个最低频率限制。（当然，在有的应用场景下，这些低频词汇会显得十分重要，就和我们有时候需要关注outlier一样）
> - 过于平凡的词汇也不用太过关注。在聚类分析中，这种平凡词汇并不能提供区分点，所以我们常常会设置一个最高频率限制

Document Frequency

给定一个词，包含该词的文档的总数

Inverse Document Frequency（IDF)

若某些词汇集中出现在少数几个文档中，那么这些词汇对这几个文档的重要性不言而喻。

$$IDF(t)=log(\frac{文档总数}{包含\ t\ 的文档数+1})$$

TFIDF

$$TFIDF(t,d)=TF(t,d)IDF(t)$$

文档向量化

依据TFIDF我们便可以将文档转变为特征向量

> 随后我们往往需要进行特征选择（可以使用频率的上下阈值，或者Information Gain），之后我们便能够将特征向量用于各种模型之中。
>
> 例如：Cosine Similarity